

DESENVOLVIMENTO DE MODELO DE IA

Reconhecimento de Utensílios de Cozinha Através do Teachable Machine

Marcela Amorim Fernandes

Sabrina Pereira Santos

João Adrison Sampaio Magalhães

Juan Battagin Barrocal

Anna Carolina

São Paulo, 13 de setembro de 2025

DESENVOLVIMENTO DE MODELO DE IA

1. Introdução

A Inteligência Artificial é um campo da ciência da computação que busca desenvolver sistemas capazes de executar tarefas de forma semelhante aos seres humanos. Muitas foram as tentativas de reprodução do modelo de pensamento do cérebro humano ao longo da história. A principal delas ocorreu na década de 1940 quando o matemático Alan Turing desenvolveu uma máquina capaz de simular processos lógicos. Essa máquina deu origem, mais tarde, ao famoso Teste de Turing que avalia o quanto uma máquina tem condições de chegar próximo a um comportamento humano.

Após anos de expansão do campo da tecnologia e da ciência de dados, assistimos ao que chamamos de “inverno da IA” em que os sistemas encontravam barreiras na capacidade de processamento do hardware existente na época. Porém, a partir do século XXI, a partir do crescimento exponencial de processamento de dados através do Big Data, a IA entrou em uma nova fase e tecnologias como Machine Learning e Deep Learning ganharam novo fôlego.

O Machine Learning atualmente, desempenha um papel fundamental dentro dos estudos da Inteligência Artificial pois é a técnica que permite que os sistemas aprendam de forma autônoma. Esse processo de aprendizado ocorre a partir de alguns parâmetros como:

- Taxa de aprendizado (learning rate): Controla a velocidade com que o modelo “aprende” a partir da entrada de dados.
- Número de épocas (epochs): Define quantas vezes o conjunto de dados será utilizado para gerar aprendizados ao modelo.
- Tamanho do lote (batch size): Indica quantos exemplos serão processados para permitir que o modelo aprenda a partir de um padrão de dados.

O ajuste adequado desses parâmetros desempenha um papel crucial na obtenção de respostas consistentes e precisas em modelos de Machine Learning, possibilitando avanços significativos no desenvolvimento de sistemas de Inteligência Artificial.

2. Objetivos e Metodologia

O presente estudo tem como objetivo desenvolver um modelo de IA através da ferramenta Teachable Machine para reconhecimento de utensílios de cozinha. A Teachable Machine é uma

ferramenta gratuita criada pelo Google capaz de criar modelos de IA de forma bastante simples, sem exigir conhecimentos avançados em programação ou ciência de dados. Suas principais características são:

- Interface intuitiva: É possível iniciar um modelo de treinamento de uma IA sem grandes instruções ou treinamentos prévios.
- Tipos de dados: É possível criar modelos a partir de imagens, arquivos de áudio ou poses corporais.
- Treinamento rápido: Com poucos parâmetros configuráveis o modelo já inicia seu próprio treinamento e já pode ser testado pelo usuário.
- É acessível e permite prototipagem: É uma ferramenta criada para testes de usuários interessados no tema e também para professores e alunos que podem testar uma ferramenta gratuita de Machine Learning.

O Machine Learning é uma área da Inteligência Artificial que permite que computadores aprendam a executar tarefas a partir de dados. O sistema encontra um padrão nesses dados e com isso consegue fazer previsões, classificações ou tomar decisões.

Existem alguns tipos de Machine Learning:

- Aprendizado supervisionado: O modelo aprende a partir de rótulos de entrada.
- Aprendizado não supervisionado: O modelo recebe dados sem rótulo prévio e deve encontrar um padrão ou agrupamento sozinho.
- Aprendizado por reforço: O modelo gera respostas e pode receber recompensas ou punições dependendo do seu grau de assertividade e, com eles pode aprender.

O Teachable Machine é um modelo de IA do tipo supervisionado pois recebe a entrada já com um rótulo específico. Portanto, para este estudo, utilizaremos entradas do tipo “fotos de utensílios de cozinha” com seus respectivos rótulos (“panelas”, “talheres” e “utensílios”) para treinamento do modelo.


3. Etapas do Projeto e Prints de Tela

O processo de treinamento e testes foi realizado diretamente na plataforma Teachable Machine e compreendeu três etapas principais: coleta e organização dos dados, treinamento do modelo e testes. Cada etapa será detalhada a seguir, ilustrada com os respectivos prints de telas do sistema.

a) Coleta e organização dos dados:

Nessa etapa, o usuário insere os dados e os classifica com os respectivos rótulos. Para este estudo, foram utilizadas imagens de “panelas”, “talheres” e “utensílios” obtidas da internet.

As imagens foram selecionadas para que tivessem o mesmo formato das que seriam apresentadas nos testes, porém sem serem idênticas. Além disso, foram escolhidas imagens com fundo branco para facilitar a identificação de padrões pelo sistema.



b) Treinamento do modelo:

Após o carregamento das imagens, o treinamento inicial foi realizado com os parâmetros padrões de sistema: número de épocas 55, tamanho do lote 16 e taxa de aprendizado 0,001, conforme imagem abaixo:

Training

Model Trained

Advanced ^

Epochs: 55 ?

Batch Size: 16 ?

Learning Rate: 0,001 ?

Reset Defaults ⌚

Under the hood 📊

O segundo teste utilizou os seguintes parâmetros: número de épocas 70, tamanho do lote 64 e taxa de aprendizado 0,00119, conforme imagem abaixo:

Training

Train Model

Advanced ^

Epochs: 70 ?

Batch Size: 64 ?

Learning Rate: 0,00119 ?

Reset Defaults ⌚

Under the hood 📊

O teste 3 foi realizado com os seguintes parâmetros: número de épocas 90, tamanho do lote 256 e taxa de aprendizado 0,00451, conforme imagem abaixo:

Training

Model Trained

Advanced ^

Epochs: 90 ?

Batch Size: 256 ?

Learning Rate: 0,00451 ?

Reset Defaults ⌚

Under the hood 📊

A variação dos parâmetros em cada teste é apresentada na tabela abaixo:

	Teste 1	Teste 2	Teste 3
Número de épocas	55	70	90
Tamanho do lote	16	64	256
Taxa de aprendizado	0,001	0,00119	0,00451

c) Testes:

Após o treinamento, o usuário apresentou imagens similares às utilizadas na fase de coleta e verificou se o sistema era capaz de identificar corretamente os objetos como “utensílio”, “talher” ou “panela”. O sistema exibe, em percentual, a probabilidade de cada objeto. A acurácia de cada classe no teste 1 foi registrada conforme abaixo:

TESTE 1					
	Item 1	Item 2	Item 3	Item 4	Acurácia Final
Talheres	0%	0%	0%	1%	0%
Panelas	98%	100%			99%
Utensílios	84%	98%	74%	99%	89%


Já no teste 2, as classes apresentaram as seguintes acurácias, com evoluções principalmente no rótulo “talheres”:

TESTE 2					
	Item 1	Item 2	Item 3	Item 4	Acurácia Final
Talheres	21%	2%	0%	15%	10%
Panelas	96%	100%			98%
Utensílios	100%	100%	100%		100%

E por fim o teste 3 apresentou as seguintes acurácias para cada uma das classes dos objetos:

TESTE 3					
	Item 1	Item 2	Item 3	Item 4	Acurácia Final
Talheres	10%	39%	3%	11%	16%
Panelas	100%				100%
Utensílios	100%				100%

Em resumo, os testes demonstraram evolução do desempenho geral com as alterações dos parâmetros de aprendizado do sistema, porém a classe “talheres” apresentou acurácia máxima de 16%, representando um desvio significativo em relação as demais classes que alcançaram valores próximos de 100% conforme mostrado no gráfico abaixo:



4. Explicação Detalhada do Processo

A coleta de imagens para treinamento da Teachable Machine foi feita a partir de arquivos disponíveis na internet. As imagens selecionadas possuíam formato semelhante às apresentadas nos testes, mas não eram idênticas, garantindo que o modelo aprendesse a generalizar padrões e não apenas memorizar exemplos. Além disso, optou-se por imagens com fundo branco, facilitando a identificação das formas pelo sistema.

O treinamento do modelo foi realizado ajustando os seguintes parâmetros:


- Número de épocas: Esperava-se que o aumento do número de épocas poderia tornar o modelo mais bem treinado. Ao longo do teste variamos esse número de 55 (padrão do sistema) até 90.
- Tamanho do lote: Nesse parâmetro, foram configurados quantos exemplos seriam processados antes de haver uma atualização no sistema, ou seja, quanto menos lotes, mas detalhado seria o aprendizado. Ao longo dos testes variamos esse parâmetro de 16 (padrão do sistema) até 256.
- Taxa de aprendizado: Nesse último parâmetro, definimos a intensidade com que o modelo seria ajustado a cada iteração. É necessário achar um ponto de equilíbrio já que uma taxa de aprendizado muito alta pode fazer com que o modelo não encontre um ponto de estabilidade, enquanto uma taxa muito baixa pode tornar o treinamento demasiadamente lento. Esse parâmetro recebeu valores que variaram de 0,001 (padrão do sistema) até 0,00451.

A variação dos parâmetros foi feita preliminar aos testes e foram feitas três rodadas de testes. Durante a execução dos testes, foi feita a captura da acurácia de acordo com o percentual de acerto do sistema em relação ao objeto apresentado. Abaixo alguns exemplos de apuração de acurácia:


Exemplo 1: Uma imagem de utensílio identificada com 100% de acerto resultou em acurácia de 100%.



Exemplo 2: Uma imagem de talher identificada com 0% de acerto resultou em acurácia de 0%.



Exemplo 3: Uma nova tentativa com o mesmo talher resultou em 10% de acerto, registrando acurácia de 10%.



A acurácia final de cada teste foi obtida pela média da acurácia individual. De modo geral, o sistema apresentou alta acurácia para identificação de objetos como panelas e utensílios e baixa acurácia para talheres, mesmo após ajustes de parâmetros e retreinamento do sistema.

5. Justificativa Técnica dos Resultados

Os resultados obtidos indicam que o modelo apresentou desempenho elevado na identificação de objetos visualmente distintos como “panelas” e “utensílios”, mas baixo desempenho na identificação de objetos menores com padrões visuais semelhantes como “talheres”. Essa diferença de desempenho pode ser explicada pelos seguintes fatores:

- Representatividade e variabilidade dos dados: Existe uma variabilidade muito maior de “talheres” e “utensílios” do que “panelas” o que torna mais fácil para o sistema, com poucas imagens de “panelas” identificar esses objetos comparando-se aos anteriores. Outro ponto a ser observado é que a variação entre “talheres” e “utensílios” é muitas vezes apenas o tamanho, sendo o formato bastante próximo, o que pode gerar confusão na classificação.
- Complexidade do padrão visual: O padrão visual de objetos como “talheres” e “utensílios” é menor do que “panelas”. Além disso “panelas” tem tamanhos maiores o que torna mais fácil a distinção de suas nuances nas imagens. Isso explica o motivo de muitas vezes o sistema ter confundido “talheres” com “utensílios”, mas pouquíssimas vezes “talheres” com “panelas”.

- Limitações de parâmetros: Apesar dos ajustes realizados nos parâmetros do sistema ao longo dos testes, alguns treinamentos de modelos podem exigir técnicas adicionais para se tornarem mais acurados como o aumento do número de dados de entrada que podem ajudar na identificação de padrões mais complexos das imagens.

Portanto, percebemos através da observação dos dados deste estudo que há um desafio técnico na identificação de objetos em que há uma diferença sutil como texturas, tamanhos, pequenas mudanças em formatos etc. Tal desafio pode ser reduzido através da configuração dos parâmetros de sistema, aumento do volume de dados de entrada ao ainda com a inclusão de outras técnicas de aprendizado que são capazes de identificar padrões sutis em dados não estruturados.

6. Análise Crítica e Sugestões de Melhorias

Embora o sistema tenha apresentado alta acuracidade na identificação de objetos maiores e visualmente distintos como “panelas” e “utensílios”, houve dificuldade na classificação de objetos menores e com padrões visuais semelhantes como “talheres”. Essa limitação sugere que o modelo, apesar de treinado com diversos ajustes em parâmetros, não conseguiu generalizar a informação para classes que possuem pouca variação em forma e cor. Essas limitações podem ser explicadas, como mencionado anteriormente por uma representatividade ou variabilidade dos dados de entrada insuficientes, alta complexidade para identificação de padrões visuais inerente a algumas classes de objetos e limitações das técnicas de aprendizado do próprio sistema utilizado.

Diante dessas limitações, algumas sugestões de melhorias são listadas abaixo:

- Aumento da base de dados: Coleta de um número maior de imagens principalmente dos rótulos com menor desempenho nos testes. Também há oportunidade na variação de ângulo das imagens, iluminação, posições etc.
- Treinamentos com pesos mais bem balanceados: Priorizar classes com menor performance durante o treinamento e ajustar os parâmetros do sistema de forma que leve mais tempo no treinamento dessas classes específicas em comparação a classes com melhor desempenho.
- Iterações contínuas: Gerar novos testes periódicos com novos exemplos e novas técnicas de aprendizado de máquina de forma a buscar fortalecer e aprimorar cada vez mais o modelo.

De maneira geral, essa análise crítica visa identificar pontos fortes e limitações a serem observadas em modelos em Machine Learning, fornecendo subsídios técnicos e ferramentas para aprimorar sua utilização em diferentes cenários de reconhecimento de objetos.